



강경구

AI 엔지니어

파인튜닝부터 프로덕션 배포까지, AI 시스템 전 과정을 직접 구현하는 엔지니어

📅 1991. 10. 31

✉ rkdrudrn1031@gmail.com

🌐 kanggyeonggu.store

☎ 010-4739-2339

🔗 github.com/conversiondev

🔗 kku1031.tistory.com

소개

sLLM 파인튜닝부터 RAG 파이프라인·AI Agent·실서비스 배포까지 AI 시스템 전 계층을 직접 구현한 AI 엔지니어입니다. 제한된 인프라에서 **고성능 모델을 양자화·최적화해 CPU 환경에 서빙**하는 등, 비용과 성능을 동시에 고려한 실용적 설계에 강점이 있습니다. 이전 직무와 다양한 현장 경험에서 쌓은 커뮤니케이션 역량을 바탕으로, 팀과 기술적 맥락을 명확히 공유하며 함께 성장하는 개발자입니다.

기술 스택

Generative AI

LLM Fine-tuning Agentic RAG Vector Search

- Fine-tuning & Serving 파이프라인 설계
- Agentic RAG 파이프라인 설계
- Vector Search 기반 임베딩·하이브리드 검색

Backend

FastAPI SSE Streaming PostgreSQL Redis

- FastAPI LLM 서빙(SSE)
- Neon · Upstash 서버리스 DB 연동

Infra

AWS EC2 Nginx Docker GH Actions Vercel

- Docker 컨테이너 기반 인프라 구축
- GitHub Actions 활용 CI/CD 배포 자동화

Computer Vision

YOLO11 MediaPipe OpenCV librosa

- YOLO11·MediaPipe 기반 실시간 객체 검출·포즈 추정
- librosa 오디오·멀티모달 신호 처리

Frontend & Mobile

Next.js React PWA Flutter

- Next.js·React App Router 기반 웹앱 UI 구축
- Zustand 상태 관리

교육

[하이미디어] 심화 생성형 AI 활용 인재 양성 과정

2026.05 – 2026.07

- ML·DL·AI 모델의 원리를 이해
- AI 모델 운영을 위한 하네스 시스템을 설계하고, 이를 기반으로 AI 서비스를 구현

[삼정KPMG] ESG 데이터 활용 AX Academy with AI Agent 3기

2025.09 – 2026.04

- AI 풀스택 개발, 클라우드 인프라, 데이터 기반 플랫폼 구축 역량 학습

[제로베이스] 백엔드 스쿨 15기

2023.04 – 2023.10

- Spring 기반 백엔드 개발 및 REST API 설계·구현 경험

[대구중앙직업전문학교] 응용 SW 엔지니어링(Java) 과정

2022.03 – 2022.09

- Java / jsp 기반 웹 애플리케이션 및 통합 시스템 개발 학습

학력

영남대학교 중어중문학과

2017 졸업

자격증

정보처리기사

필기 합격

2026 · 한국산업인력공단 2회

소개

광고 집행 전 AI 소비자 시뮬레이션으로 사전 검증·개선

집행 후 실제 성과 진단과 조치 제안까지 연결하는 광고 운영 플랫폼

담당 기능

- ▶ Meta 광고 캠페인 실시간 실측 연동
- Graph API 성과 조회 → 대시보드·진단·어시스턴트 동기화 → 캠페인·리드폼·소재·미리보기 연동
→ 배치 insights·TTL 캐시·토큰 암호화
- ▶ 이상 감지·HITL 승인 플로우
- 관측 → 기대 비교 → 진단 → 조치 제안 → Tier 판정 → 자율 통과/사람 승인 분기 → 단계적 에스컬레이션 제안
- ▶ 자율 운영 워커 (APScheduler)
- 인프로세스 스케줄러로 이상 스캔·리포트·예산 제안 주기 실행 → "관측은 자율, 집행은 사람" 경계
→ write는 HITL 승인 분리
- ▶ Deep Agent 운영 채팅 어시스턴트
- 멀티 에이전트 시스템의 오케스트레이터 답에이전트 구현
- LangGraph ReAct(Agentic RAG)에 plan→act→observe 루프로 운영·생성 작업을 한 채팅에서 조율
- Web Speech API 기반 음성 입력(STT)·음성 출력(TTS) 지원
- ▶ 채팅 에이전트 메모리 3단 구조
- 최근 원문·요약·롱텀 회수 3계층 컨텍스트 조립 → 요약(맥락)·실행이력(사실) 저장·검색 분리
→ 롱텀은 tsvector(GIN) 키워드 회수
- ▶ RAG 검색·품질 평가 파이프라인
- pgvector 벡터 검색 + GIN 키워드 검색 → RRF로 결과 융합 → 하이브리드 검색 구축
- 검색·응답 품질 5개 지표 골든셋 정량 평가 체계 구축 · LangSmith 평가 결과 추적 · 합성 질문 23개 환각 검증

문제해결

- ▶ RAG 검색 정확도 개선
- 정답 문서가 검색 상위에 안정적으로 노출되지 않음 → 청크 크기 조정·리랭커 도입·few-shot 보강
→ Hit Rate 단일 0.886·복합 0.800 → 모두 1.000, MRR 0.705 → 0.938(단일) · 0.634 → 0.833(복합)
- ▶ RAG 환각 저감·근거 충실도 개선
- 근거 충분성 평가(CRAG-lite) + KB 게이트 + 자기교정 검색 도입 → 근거 부족 답변 차단·재검색
→ ADVISE 골든셋 기준 faithfulness 0.51 → 1.00 개선
- ▶ 채팅 메모리 롱텀 일원화 리팩터링
- 매 턴 LLM 추출 기억·이중 적재 방식 → 쓰기를 실행 확정 지점으로 단일화, LLM은 읽기·파생만 담당
→ 원본 이력으로 요약·선택 재계산 가능
- ▶ 데이터 부재를 직접 해결
- 모델 검증에 쓸 실측 성과 부재 → Meta에 사비로 트래픽·잠재고객 캠페인을 직접 집행
→ 실측 지표(CTR·CPC 등)를 직접 확보 → 합성 데이터의 한계 극복 → 현실 정합성 검증
- CVR(구매전환)의 경우, 발품할 제품이 없어 클릭 후 설문 조사 제출률로 대체
- ▶ Meta API 등급 제약 대응 + 프로덕션 전환 설계
- Standard 호출 제한 하에서 15일 내 실호출 500개 적립 → 사업자 등록증 발급 후 Advanced 상향 신청
→ 선제 구현해 등급 승인 즉시 실서비스로 전환

사용기술 EXAONE 3.5 7.8B · Llama 3.2 3B · Gemini · PyTorch · PEFT · QLoRA · Unsloth · LangChain ·
LangGraph · FastMCP · BGE-M3 · FAISS · pgvector · FastAPI · Spring Boot · PWA · AWS EC2

소개

비정형 업무 데이터(이력서·메일·회의록) 통합 HCM 플랫폼
ISO 30414 기반 역량 정량화와 채용 이후 역량 발현·성장 추적

아키텍처 설계

- ▶ Polyglot
 - Spring Boot(인증 게이트웨이) + FastAPI(AI 연산) → 업무 API와 AI 로직 분리
- ▶ Hexagonal(라이트)
 - domain / application / infrastructure 레이어 분리 → 확장성 확보
- ▶ Hub-and-Spoke Star 토폴로지
 - 중앙 허브는 라우팅만, 무거운 모델은 Spoke에서 실행

주요 기능

- ▶ 비정형 문서 처리 및 초기 역량 정량화
 - 멀티 포맷 문서 파싱 → 텍스트 레이어 추출 + 스캔본 **OCR** → LLM 의미 분석
→ 5대 핵심 역량 정량화(리더십·기술력·창의성·협업·적응력)
- ▶ 커뮤니케이션 데이터 기반 역량 추적 파이프라인
 - 외부 메일 수신 → LLaMA LoRA 스팸 메일 분류
 - 성과 데이터(메일·회의록 단어 기반) 통합 → 5대 역량 초기(이력서) 대비 현재(이력서+성과) 성장 추이 도출
- ▶ SSE 스트리밍 채팅형 인사 조회
 - **LangGraph** 기반 RAG 에이전트, 직원·성과·공시·역량 단일·복합 질의
→ 12개 시나리오 RAG·**Tool Calling** 검증 (평균 성공률 0.95)
- ▶ 역량 온톨로지·지식베이스 구축
 - 직무역량 원천(O*NET·NCS 등) 11.8만 건 → **BGE-M3 임베딩** → FAISS K-Means · UMAP
→ 파인튜닝 EXAONE 자동 라벨링 → 채팅 RAG 근거 지식베이스

문제해결

- ▶ LLM 학습 최적화 및 성능 개선
 - Transformers + PEFT + **bitsandbytes 4bit 양자화** 적용 → EXAONE 모델 학습 속도 약 2배 개선
 - **Unsloth** 기반 LLaMA 학습 최적화 → 학습 속도 2.5~3배 향상 및 메모리 성능 개선
- ▶ GPU 파인튜닝 모델을 CPU 서버에 서빙 (llama.cpp)
 - 로컬 GPU 파인튜닝한 모델 → GPU 없는 EC2 배포 → 포맷 변환·메모리 문제 연쇄 발생
 - 4비트(NF4) 학습 모델을 배포용 4비트(**GGUF Q4_K_M**)로 재변환 → 변환 중 tokenizer 손상 → 수동 패치
 - 별개로 OOM은 n_ctx 축소로 해결
- ▶ 대용량 벡터 검색 아키텍처 설계
 - Neon 스토리지 한도 → 11.8만 건 임베딩 적재 불가 → SSL 타임아웃
 - 검색 계층 이원화 — 정적·대용량(역량 11.8만·공시) FAISS 인메모리
 - 동적·트랜잭션(직원) **HNSW-FlatIP** 검색 최적화, 11.8만 건 인덱스 빌드 ~12초

FOM — 댄스 동작 분석 AI 평가 플랫폼

심화 · 6인 · 2026.05.18 – 05.22 · [GitHub](#)

사용기술 FastAPI · MediaPipe · YOLO11 · librosa · Flutter

담당 기능

- 비전 모델 기반 영상 **키포인트 추출** → 레퍼런스 대비 동작 채점 End-to-End 파이프라인 구현

ESG 공급망 리스크 관리 및 PCF 산정 지원 시스템

삼성KPMG · 4인 · 2026.03 – 04

사용기술 WebSocket · Slack · Gmail API · Vercel

담당 기능

- 백그라운드 워커 비동기 알림 파이프라인, **WebSocket 실시간 브로드캐스트**·Slack/Gmail API 연동

Keyword — 약속 일정 관리 서비스

제로베이스 · 5인 · 2023.09 – 10 · [GitHub](#)

사용기술 Spring Boot · Elasticsearch · OAuth2

담당 기능

- Elasticsearch** 기반의 고성능 회원 검색 기능 구현

실무 경험

(주)화산시스템 · 인터페이스팀

2022.09 – 2022.12

국내 대학병원 진단검사의학과 LIS(진단검사 정보시스템)를 개발·운영하는 전문 기업 (Visual Basic 기반)

- 대학병원 진단검사의학과 LIS 시스템 유지보수 및 운영 지원
- 의료 장비와 LIS 간 데이터 인터페이스 연동 상태 점검 및 **장애 대응**
- 로그 분석 · 네트워크 점검 · 백업 데이터 관리 등 시스템 운영 전반 지원
- 사용자 문의 대응 및 현장·원격 기반 프로그램 사용 지원
- 의료 데이터 연동 구조와 운영 환경을 직접 경험하며 시스템 안정성 관점의 기반을 다짐

기타 경력

한국 YMCA 전국연맹 국제개발협력팀 / 대구 YMCA 남자 중장기 청소년 쉼터

2018 – 2020

- 국내외 다양한 대상자와의 소통을 통해 상황에 맞는 커뮤니케이션 및 조율 능력 체득
- 현장 중심 문제 해결 경험을 바탕으로 팀 협업 및 조직 목표 달성 기여